UNIVERSITÉ TOULOUSE III PAUL SABATIER

Université Fédérale Toulouse Midi-Pyrénées

Compte Rendu – Projet n°01

Facteurs de risques pour le développement du diabète

DARWICHEH Jana
SIRB Ema

INFORMATIQUE SCIENTIFIQUE 2
MECA2-INFOS2

le mardi 14 avril 2026

Table des matières

1 Présentation du sujet **2**
1.1 Qu'est-ce que le diabète ? 2
1.2 Ampleur mondiale 2
1.3 Objectifs du projet 2

2 Méthodologie **3**
2.1 Présentation du jeu de données BRFSS 2015 3
2.2 Structure du DataFrame Pandas 3
2.3 L'ensemble des graphiques 4

3 Questionnement **5**
3.1 Question 1 – Facteur le plus aggravant 5
3.1.1 Démarche : calcul du risque relatif 5
3.1.2 Visualisation : vue d'ensemble et classement 6
3.1.3 Résultats 7
3.2 Question 2 – Facteur le plus protecteur 8
3.2.1 Aperçu de quelques codes 8
3.2.2 Résultats 9
3.3 Question 3 – Impact du Body Mass Index sur le Diabète 10
3.3.1 Résultats 10

4 Conclusion **12**
4.1 Synthèse des résultats 12
4.2 Déclaration d'usage d'IA générative 12
4.3 Lien Github 12

1 Présentation du sujet

On cherche tout d'abord à comprendre le contexte autour de la problématique de notre sujet.

1.1 Qu'est-ce que le diabète ?

Le diabète est une maladie chronique qui se caractérise par un taux de sucre trop élevé dans le sang, appelé hyperglycémie. Cela arrive lorsque le pancréas ne produit pas assez d'insuline, ou lorsque le corps n'utilise plus correctement cette hormone, qui sert à réguler le glucose.
Sans traitement adapté, le diabète peut provoquer de graves complications : maladies du cœur et des vaisseaux (infarctus, AVC), problèmes aux reins, atteintes des yeux pouvant aller jusqu'à la cécité, troubles des nerfs, et un risque plus important d'amputation des jambes ou des pieds.
On distingue trois grandes formes de diabète :

- ↪ **Diabète de type 1 (DT1) :** maladie auto-immune rare, survenant généralement chez les jeunes, dans laquelle le système immunitaire détruit les cellules bêta du pancréas productrices d'insuline.
- ↪ **Diabète de type 2 (DT2) :** forme la plus répandue (90 à 95 % des cas), associée à des facteurs de mode de vie (obésité, sédentarité, alimentation déséquilibrée) et génétiques.
- ↪ **Prédiabète :** état intermédiaire ou la glycémie est anormalement élevée sans atteindre le seuil diagnostique du diabète avère, mais constituant un facteur de risque majeur d'évolution vers le DT2.

1.2 Ampleur mondiale

Selon l'Organisation mondiale de la Santé (OMS), plus de 425 millions de personnes vivaient avec le diabète en 2015, et ce nombre pourrait dépasser 700 millions d'ici 2045. Le diabète est donc l'un des plus grands enjeux de santé publique du XXIe siècle et mobilise d'importantes ressources dans les systèmes de santé du monde entier.
Aux États-Unis, le CDC (Centers for Disease Control and Prevention) estime que plus de 37 millions de personnes sont diabétiques. Environ 96 millions d'Américains présentent aussi un prédiabète, souvent sans le savoir. Cette situation explique la mise en place de grandes études annuelles, comme l'enquête BRFSS.

1.3 Objectifs du projet

Ce projet a pour but d'exploiter la base de données BRFSS 2015 afin d'identifier et de quantifier les principaux facteurs de risque et facteurs protecteurs du diabète au sein de la population américaine adulte. Les objectifs spécifiques sont :

- Identifier le facteur individuel le plus aggravant le risque de développer du diabète (ou prédiabète).
- Identifier le facteur individuel le plus protecteur, et analyser les combinaisons de facteurs protecteurs.
- Etudier la corrélation entre l'Indice de Masse Corporelle (IMC/BMI) et la prévalence du diabète, et proposer un modèle d'ajustement de courbe.

2 Méthodologie

2.1 Présentation du jeu de données BRFSS 2015

Le **Behavioral Risk Factor Surveillance System (BRFSS)** est une enquête téléphonique nationale américaine conduite annuellement par le CDC. En 2015, elle a collecté des informations auprès de plus de 400 000 adultes résidant dans les 50 Etats américains et le District of Columbia. Ce jeu de données est largement utilisé dans la recherche en santé publique pour étudier les déterminants comportementaux et socio-démographiques des maladies chroniques. Le fichier exploite dans ce projet (diabetes_012_health_indicators_BRFSS2015.csv) contient 253 680 observations (lignes) et 22 variables (colonnes), dont la variable cible Diabetes_012.
La variable cible `Diabetes_012` prend trois valeurs :

- **0** – Individu sain (pas de diabète),
- **1** – Prédiabète,
- **2** – Diabète avéré.

2.2 Structure du DataFrame Pandas

On illustre ci-dessous le chargement et la préparation des données avec la bibiliothèque Pandas :

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
from scipy.optimize import curve_fit

# Lecture du fichier CSV
df = pd.read_csv('diabetes_012_health_indicators_BRFSS2015.csv')

print(f"Dimensions : {df.shape[0]} lignes x {df.shape[1]} colonnes")
print(df.describe().round(2))

# Variable cible en categories lisibles
df['Statut'] = df['Diabetes_012'].map(
    {0.0: 'Sain', 1.0: 'Prediabete', 2.0: 'Diabete'}
)

# Variable binaire : atteint = prediabete OU diabete
df['Atteint'] = (df['Diabetes_012'] > 0).astype(int)
```

Extrait de code 1: Chargement du CSV et création du DataFrame

Choix pythonique : Pour faciliter l'analyse comparative, on a créé une variable binaire `Atteint` : elle vaut 1 si l'individu est prédiabétique ou diabétique (`Diabetes_012 > 0`), et 0 sinon. Cela permet de calculer directement le **taux de diabète** dans chaque sous-groupe, et d'en dériver le risque relatif.

2.3 L'ensemble des graphiques

La figure 1 présente une matrice de 9 sous-graphiques offrant une première exploration du jeu de données. Elle couvre la répartition des statuts diabètiques, les tendances par age, les distributions d'IMC, les risques relatifs de chaque facteur, et des combinaisons bivariées (heatmaps, barres empilées).

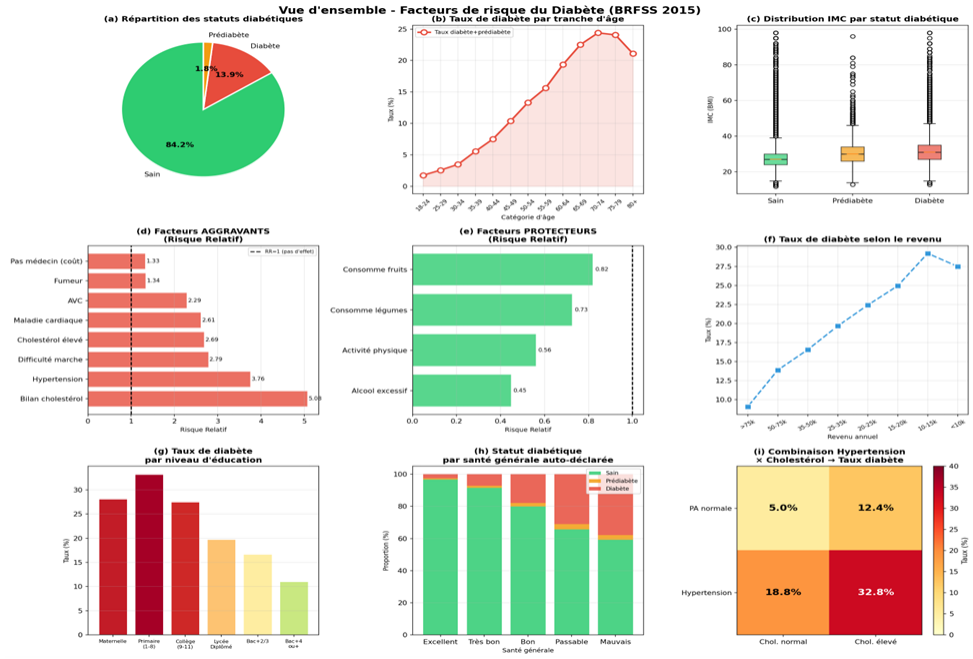

FIGURE 1 – Matrice de 9 graphiques - Vue d'ensemble des facteurs de risque du diabete (BRFSS 2015)

Les résultats de la répartition (camembert, graphique (a)) révèlent que sur 253 680 participants :

- 84,2 % sont sains (Diabetes_012 = 0), soit 213 703 individus.
- 13,9 % sont diabètiques (Diabetes_012 = 2), soit 35 346 individus.
- 1.8 % présentent un prédiabète (Diabetes_012 = 1), soit 4 631 individus.

La faible proportion de prédiabètes (1.8 %) reflète probablement un biais de détection : beaucoup d'états prédiabétiques restent non diagnostiques. Pour les analyses suivantes, nous avons donc regroupe prédiabète et diabète dans une variable binaire 'Atteint' afin d'augmenter la puissance statistique.
Le graphique (b) (ligne + symboles) montre une progression quasi-monotone du taux de diabète avec l'âge. Les 18-24 ans présentent un taux de moins de 2 %, tandis que les 65-69 ans dépassent 20 %. Cette courbe en S confirme que l'âge est un facteur de risque majeur, bien qu'il ne soit pas modifiable. Le graphique (f) illustre une relation inverse entre le revenu et le taux de diabète : les individus disposant de moins de 10 000 $ annuels présentent un taux de 27,5 %, contre moins de 10 % pour les revenus supérieurs à 75 000 $. Cette inégalité sociale face au diabète est un enjeu majeur de santé publique.

3 Questionnement

3.1 Question 1 – Facteur le plus aggravant

↪ Quel est le facteur le plus aggravant en ce qui concerne le risque de développer du diabète (ou prédiabète) ? Étudier également quelques combinaisons de facteurs qui vous semblent pertinentes.

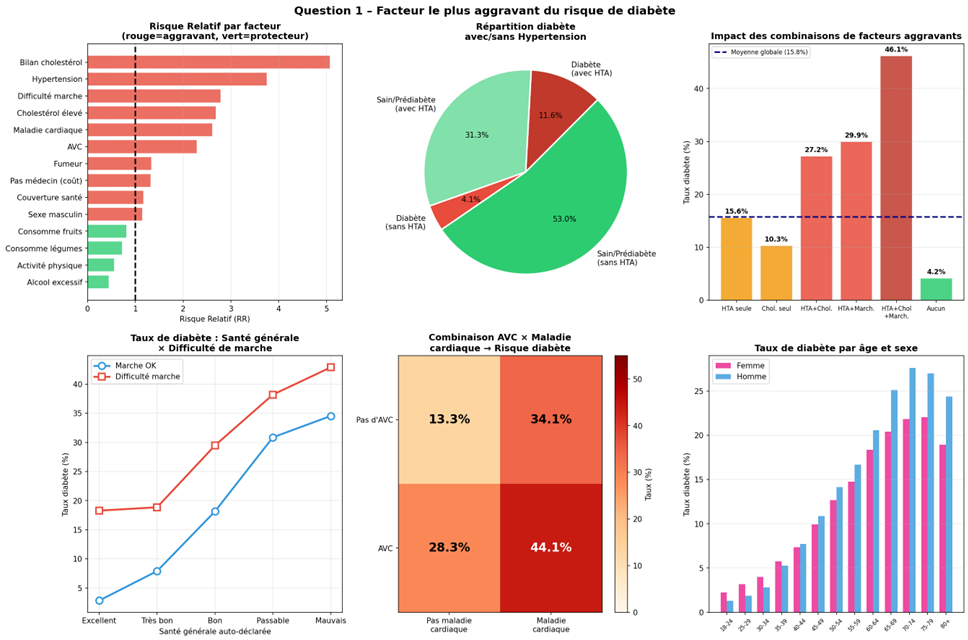

FIGURE 2 – Analyse detaillée des facteurs aggravants - Risques Relatifs, combinaisons et interactions

3.1.1 Démarche : calcul du risque relatif

La notion de **risque relatif** (RR) est l'outil central de cette analyse. Pour un facteur binaire F :

$$\mathrm{RR}(F) = \frac{P(\text{Atteint} \mid F = 1)}{P(\text{Atteint} \mid F = 0)}$$

Un RR > 1 signifie que la présence du facteur augmente le risque de diabète. Plus le RR est élevé, plus le facteur est aggravant.

```python
facteurs_binaires = [
    'HighBP', 'HighChol', 'CholCheck', 'Smoker', 'Stroke',
    'HeartDiseaseorAttack', 'PhysActivity', 'Fruits', 'Veggies',
    'HvyAlcoholConsump', 'AnyHealthcare', 'NoDocbcCost',
    'DiffWalk', 'Sex'
]

risques = {}
for f in facteurs_binaires:
    taux_1 = df[df[f] == 1]['Atteint'].mean() * 100  # taux si facteur present
    taux_0 = df[df[f] == 0]['Atteint'].mean() * 100  # taux si facteur absent
    risque_relatif = taux_1 / taux_0 if taux_0 > 0 else np.nan
    risques[f] = {
        'taux_present': taux_1,
        'taux_absent':  taux_0,
        'risque_relatif': risque_relatif,
        'delta': taux_1 - taux_0   # difference absolue
    }

risques_df = (pd.DataFrame(risques).T
                .sort_values('risque_relatif', ascending=False))
```

Extrait de code 2: Calcul du risque relatif pour chaque facteur binaire

3.1.2 Visualisation : vue d'ensemble et classement

On a codé plusieurs graphiques pour analyser les facteurs aggravants. On s'est concentré sur des camemberts mais aussi des histogrammes, etc qui ont été vus plusieurs fois en TPs. Cependant, on a voulu aussi travailler sur un heatmap pour étudier la combinaison AVC x Maladie ayant pas eu un entrainement solide dessus.
Le graphique (a) de la Figure 2 représente en barres horizontales le risque relatif de chaque facteur aggravant. Le code ci-dessous génère ce graphique ainsi que la heatmap combinant AVC et maladie.

```python
fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# --- (a) Risque relatif de tous les facteurs ---
ax = axes2[0, 0]
sorted_r = risques_df.sort_values('risque_relatif', ascending=True)
colors_bar = ['#e74c3c' if v > 1 else '#2ecc71' for v in sorted_r['risque_relatif']]
bars_all = ax.barh(sorted_r['label'], sorted_r['risque_relatif'],
                   color=colors_bar, alpha=0.8, edgecolor='white')
ax.axvline(x=1, color='black', linestyle='--', linewidth=2)
ax.set_xlabel('Risque Relatif (RR)', fontsize=10)
ax.set_title('Risque Relatif par facteur\n(rouge=aggravant, vert=protecteur)',
             fontweight='bold')
ax.grid(True, alpha=0.3, axis='x')

# --- (b) Heatmap AVC x Maladie ---
ax = axes2[1, 1]
combo2 = df.groupby(['Stroke', 'HeartDiseaseorAttack'])['Atteint'].mean() * 100
m2 = combo2.unstack().values
im2 = ax.imshow(m2, cmap='OrRd', aspect='auto', vmin=0, vmax=55)
ax.set_xticks([0,1])
ax.set_xticklabels(['Pas maladie\ncardiaque', 'Maladie\ncardiaque'])
ax.set_yticks([0,1])
ax.set_yticklabels(['Pas d\'AVC', 'AVC'])
plt.colorbar(im2, ax=ax, label='Taux (%)')
for i in range(2):
    for j in range(2):
        ax.text(j, i, f'{m2[i,j]:.1f}%', ha='center', va='center',
                fontweight='bold', fontsize=16,
                color='white' if m2[i,j] > 35 else 'black')
ax.set_title('Combinaison AVC × Maladie\ncardiaque → Risque diabète', fontweight='bold')
```

Extrait de code 3: Graphiques du risque relatif des facteurs aggravants et la combinaison AVC x Maladie

3.1.3 Résultats

Le bilan de cholestérol (CholCheck) affiche le RR le plus élevé (5.08) (**cf. ligne 70 du fichier .py**), mais ce résultat est maladroit : les personnes qui réalisent un bilan de santé sont précisément celles qui présentent déjà des facteurs de risque. Il s'agit d'un biais de détection (detection bias) et non d'un lien de causalité biologique. En excluant ce biais, **l'HYPERTENSION ARTERIELLE (HighBP)** se révèle être le facteur le plus aggravant avec un Risque Relatif de 3.76. Concrètement, les personnes hypertendues présentent un taux de diabète+prédiabète de 27.1 %, contre seulement 7.2 % chez les non-hypertendus. Ce lien s'explique par des mécanismes physiopathologiques communs : résistance à l'insuline, inflammation chronique, dysfonctionnement de l'endothélium vasculaire.
La heatmap (graphique (e) de la figure 2) illustrant la combinaison AVC x Maladie cardiaque montre que les individus ayant subi les deux événements vasculaires présentent un taux de diabète+prédiabète de 44,1 %, soit le taux le plus élevé observe dans l'ensemble du jeu de

données. Ces résultats confirment que le diabète de type 2 et les maladies cardiovasculaires partagent des mécanismes étiologiques communs (syndrome métabolique).

3.2 Question 2 – Facteur le plus protecteur

↪ Quel est le facteur le plus protecteur pour se protéger du diabète ? Étudier également quelques combinaisons de facteurs qui vous semblent pertinentes.

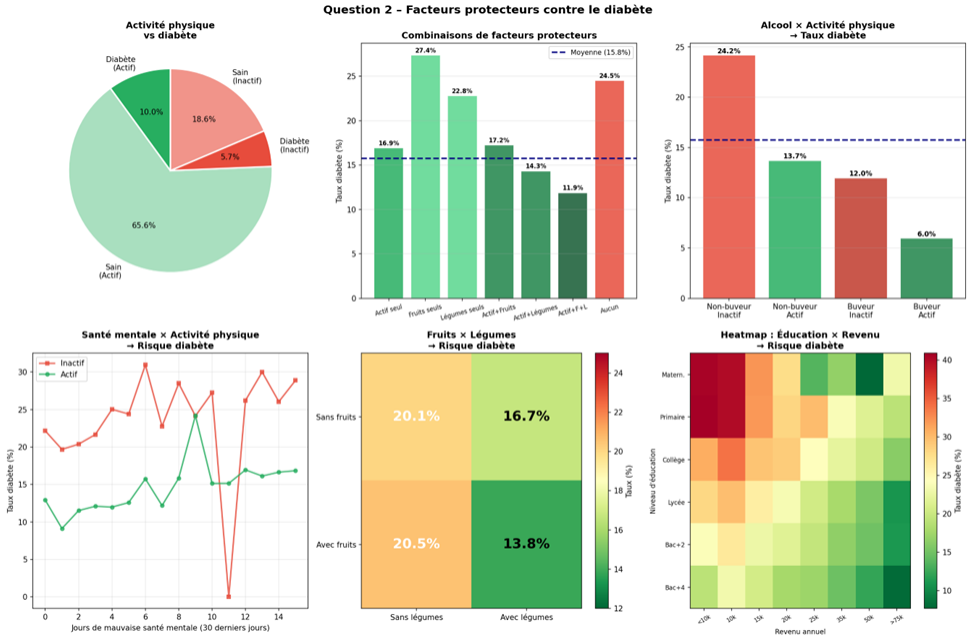

FIGURE 3 – Analyse détaillée des facteurs protecteurs - Combinaisons optimales et interactions

Deux facteurs présentent des Risques Relatifs nettement inférieurs à 1, indiquant un effet protecteur significatif (cf. ligne 70 du fichier python) :

- Absence de consommation excessive d'alcool (HvyAlcoholConsump = 1 signifie buveur excessif) : RR = 0.45. Les buveurs excessifs ont un taux de seulement 7.3 %, contre 16.3 % chez les non-buveurs. Ce résultat, contre-intuitif en apparence, est expliqué par des biais de sélection : les buveurs excessifs sont souvent plus jeunes, plus minces, et rarement diagnostiques pour une pathologie chronique.
- Activité physique régulière (PhysActivity) : RR = 0.56. Les personnes physiquement actives présentent un taux de 13.2 %, contre 23.6 % chez les sédentaires. Ce résultat est robuste biologiquement : l'exercice physique améliore la sensibilité à l'insuline, réduit la glycémie à jeun et diminue la masse grasse viscérale.

L'**activite physique** constitue donc le facteur protecteur le plus cliniquement pertinent et le plus actionnable sur le plan de sante publique.

3.2.1 Aperçu de quelques codes

```python
# (a) Camembert : actif physiquement vs non
ax = axes3[0, 0]
actif = df[df['PhysActivity'] == 1]
inactif = df[df['PhysActivity'] == 0]
labels_pie3 = ['Diabète\n(Actif)', 'Sain\n(Actif)', 'Diabète\n(Inactif)', 'Sain\n(Inactif)']
sizes3 = [actif['Atteint'].sum(), len(actif)-actif['Atteint'].sum(),
          inactif['Atteint'].sum(), len(inactif)-inactif['Atteint'].sum()]
c3 = ['#27ae60', '#a9dfbf', '#e74c3c', '#f1948a']
wedges, texts, ats = ax.pie(sizes3, labels=labels_pie3, colors=c3,
                            autopct='%1.1f%%', startangle=90,
                            wedgeprops={'edgecolor':'white','linewidth':2})
ax.set_title('Activité physique\nvs diabète', fontweight='bold')

# (b) Combinaisons protectrices - Barres
ax = axes3[0, 1]
combos_prot = {
    'Actif seul': df[(df['PhysActivity']==1)&(df['Fruits']==0)&(df['Veggies']==0)]\['Atteint'].mean(
    'Fruits seuls': df[(df['PhysActivity']==0)&(df['Fruits']==1)&(df['Veggies']==0)]['Atteint'].mean
    'Légumes seuls': df[(df['PhysActivity']==0)&(df['Fruits']==0)&(df['Veggies']==1)]['Atteint'].mean
    'Actif+Fruits': df[(df['PhysActivity']==1)&(df['Fruits']==1)&(df['Veggies']==0)]['Atteint'].mean
    'Actif+Légumes': df[(df['PhysActivity']==1)&(df['Fruits']==0)&(df['Veggies']==1)]['Atteint'].mean
    'Actif+F+L': df[(df['PhysActivity']==1)&(df['Fruits']==1)&(df['Veggies']==1)]['Atteint'].mean()*1
    'Aucun': df[(df['PhysActivity']==0)&(df['Fruits']==0)&(df['Veggies']==0)]['Atteint'].mean()*100,
}
mean_global = df['Atteint'].mean()*100
colors_prot = ['#27ae60','#58d68d','#58d68d','#1e8449','#1e8449','#145a32','#e74c3c']
b3 = ax.bar(list(combos_prot.keys()), list(combos_prot.values()),
            color=colors_prot, alpha=0.85, edgecolor='white')
ax.axhline(y=mean_global, color='navy', linestyle='--',
           linewidth=2, label=f'Moyenne ({mean_global:.1f}%)')
ax.set_ylabel('Taux diabète (%)')
ax.set_title('Combinaisons de facteurs protecteurs', fontweight='bold')
ax.legend(fontsize=9)
ax.tick_params(axis='x', labelsize=8, rotation=15)
ax.grid(True, alpha=0.3, axis='y')
for bar, val in zip(b3, combos_prot.values()):
    ax.text(bar.get_x()+bar.get_width()/2, val+0.3,
            f'{val:.1f}%', ha='center', fontsize=8, fontweight='bold')
```

Extrait de code 4: Graphiques du camembert de la figure 3 ainsi que les barres illustrant les combinaisons protectrices

3.2.2 Résultats

La figure 3 (graphique (b)) met en évidence l'effet cumulatif des facteurs protecteurs. L'analyse de 6 combinaisons impliquant l'activité physique, la consommation de fruits et de légumes révèle que la combinaison optimale Actif + Fruits + Legumes conduit à un taux de diabète de 11.9 %, soit une réduction de 46 % par rapport au profil sans aucun facteur pro-

tecteur. Cette synergie démontre l'importance d'une approche globale de prévention fondée sur l'hygiène de vie.
La heatmap éducation x revenu (figure 3, graphique (f)) révèle un gradient socioéconomique net : les individus les moins éduqués et les plus pauvres cumulent des taux de diabète supérieurs à 30 %, tandis que les diplômés aux revenus élevés descendent sous 10 %. Cela confirme que l'éducation et le revenu constituent des déterminants sociaux majeurs de la santé, influençant indirectement le risque de diabète via l'accès aux soins, les habitudes alimentaires et le niveau d'activité physique.

3.3 Question 3 – Impact du Body Mass Index sur le Diabète

↪ On souhaite étudier un peu plus en détail l'impact du Body Mass Index sur le développement du diabète. Proposer une analyse et une mise en forme des données permettant de voir s'il existe une corrélation entre ces deux éléments. S'il existe une corrélation, en donner la nature (fitting de courbes).

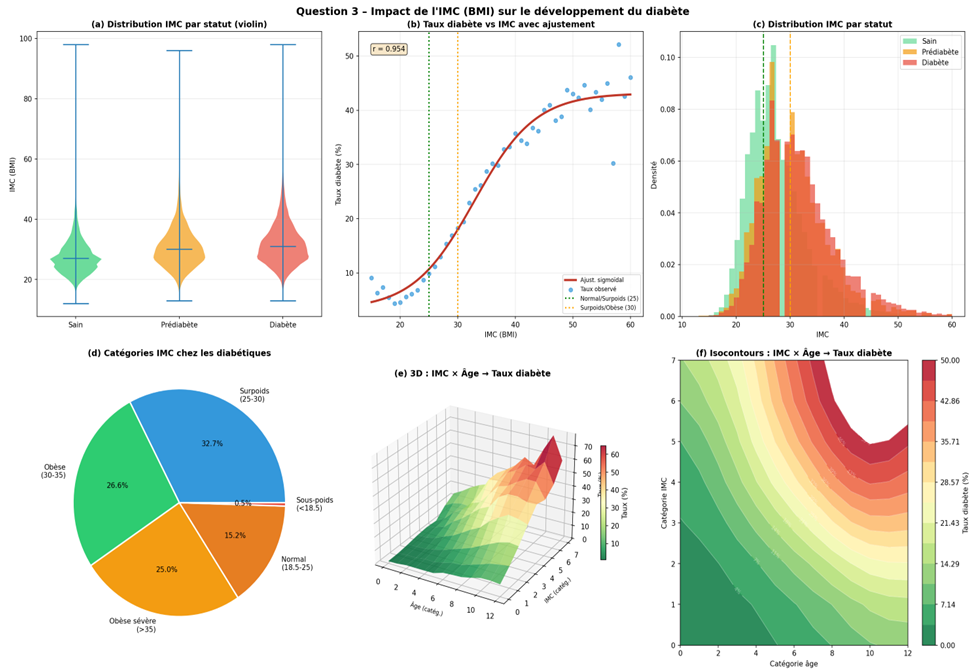

FIGURE 4 – Analyse complete de la relation IMC-Diabete - Violin, ajustement sigmoidal, 3D et isocontours

L'Indice de Masse Corporelle (IMC ou BMI en anglais) est defini comme le rapport poids/taille$\hat{2}$ (en kg/m$\hat{2}$). Les categories standard de l'OMS sont :

- MC < 18.5 : Sous-poids
- 18.5 <= IMC < 25 : Poids normal
- 25 <= IMC < 30 : Surpoids (overweight)
- IMC >= 30 : Obésite (classes I, II, III selon le niveau)

3.3.1 Résultats

Le graphique en violon (figure 4a) illustre clairement que la distribution de l'IMC diffère significativement entre les trois groupes. La médiane des diabétiques (environ 31.5) dépasse

de plus de 4 points celle des personnes saines (environ 27.2). La distribution des diabétiques est plus étalée vers les valeurs élevées, avec une queue épaisse au-delà de 40.
Le graphique (b) de la figure 4 présente le taux de diabète observe pour chaque valeur d'IMC arrondie à l'entier, accompagne d'une courbe d'ajustement de type sigmoïdal. Le modèle sigmoïdal a été ajusté via la fonction scipy.optimize.curve_fit, référence ci-dessous :

```
# (b) Taux de diabète par BMI avec fitting - COURBE AVEC SYMBOLES + LIGNE
ax = axes4[0, 1]
# Regrouper BMI par intervalles de 1
df_bmi = df[(df['BMI'] >= 15) & (df['BMI'] <= 60)].copy()
bmi_groups = df_bmi.groupby(df_bmi['BMI'].round(0))
bmi_taux = bmi_groups['Atteint'].mean() * 100
bmi_count = bmi_groups['Atteint'].count()
bmi_x = bmi_taux.index.values
bmi_y = bmi_taux.values
# Filtrer les groupes avec assez d'observations
mask = bmi_count > 50
bmi_x = bmi_x[mask]
bmi_y = bmi_y[mask]

# Fitting sigmoïde / logistique
# Source curve_fit : https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.curve_fit.h
def sigmoid(x, L, k, x0, b):
    return L / (1 + np.exp(-k * (x - x0))) + b
```

Extrait de code 5: Fitting de courbes

Le modèle retenu est une **fonction logistique à 4 paramètres** :

$$f(x) = \frac{L}{1 + e^{-k(x-x_0)}} + b$$

où L est l'amplitude, k la pente, x_0 le point d'inflexion et b le décalage vertical.
NB : Etant donné qu'il s'agit d'un concept un peu compliqué, on s'est fait aidé par cette vidéo YouTube (How to fit graph with sigmoidal curve in origin) et ce blog de Daniel Hagnoul.
La surface 3D (figure 4e) et les isocontours (figure 4f) représentent la progression conjointe du risque en fonction de l'IMC et de l'âge. Ces visualisations révèlent deux effets indépendents et additifs :

- Effet âge : pour un IMC donné, le risque augmente systématiquement avec l'âge (les courbes de niveaux sont inclinées vers le haut-droite).
- Effet IMC : pour un âge donne, le risque augmente fortement avec l'IMC, avec une accélération marquée entre 25 et 35.

La zone de risque maximal (taux > 40-50 %) correspond aux individus âgés de plus de 55 ans avec un IMC supérieur à 35, soit le profil 'obese âge'. Ces constats corroborent les recommandations cliniques qui préconisent la surveillance glycémique systématique à partir de 45 ans et/ou en cas d'IMC > 25.

4 Conclusion

4.1 Synthèse des résultats

L'analyse du jeu de données BRFSS 2015 a permis de mettre en évidence plusieurs résultats clés, cohérents avec la littérature scientifique internationale :

- L'hypertension artérielle est le facteur cliniquement aggravant le plus puissant. Hypertendue et diabète partagent des mécanismes physiopathologiques communs lies a la résistance a l'insuline et au syndrome métabolique.
- L'activité physique régulière constitue le facteur protecteur le plus pertinent et modifiable. Combinées a une alimentation riche en fruits et légumes, les habitudes de vie saines peuvent réduire le risque de diabète.
- L'IMC est fortement corrèle au risque de diabète; avec plus de 55 % des diabétiques qui sont en surpoids ou obèses.
- Les déterminants socioéconomiques (revenu, éducations) jouent un rôle fondamental, amplifiant ou atténuant les autres facteurs de risque.

Il faut noter qu'il y a des limites à cette étude; notamment les biais de déclaration (des personnes qui mal-estiment leur consommation d'alcool, leur poids, etc) ainsi que ceux de détection (l'état de prédiabète étant une condition fréquemment non-diagnostiquée).

4.2 Déclaration d'usage d'IA générative

On a utilisé **Claude Sonnet 4.6** pour expliquer le fonctionnement de code (% 20) pour les combinaisons de quelques graphiques, ainsi que le fitting de courbes et les méthodes (équations) les plus optimales pour faire l'ajustement. De plus, on l'a consulté pour générer des tâches LaTex répétitives ou reformulation de texte ayant l'impression de contenir de mots qui se répètent (et les codes avec des *print* répétitifs.

4.3 Lien Github

Si besoin, voici le lien vers le Github Repository du projet :
https://github.com/janadarwicheh/Risk-Factors-for-the-Development-of-Diabetes